




REGRESJA LINIOWA


Golem bootcamp 2021

Problem regresji liniowej

Mamy zbiór punktów i chcemy dopasować do niego linię, która będzie najlepiej opisywać wszystkie dane



$$y = \beta_0 + \beta_1 x$$



Mean Square Error – funkcja straty

Jak sprawdzić jak daleko jesteśmy od prawdziwego wyniku?

$$\frac{1}{n} \sum_{i=1}^n (y_i - \text{pred}_i)^2$$

Zmniejszamy β_0 i β_1 o stałą wartość α

Dlaczego to nie zadziała?

- Jeśli α jest za duża to będziemy mieli duży error
- Jeśli α jest za mała to będziemy mieli długi czas liczenia

Liczymy pochodne cząstkowe z funkcji straty


Pochodna po β_0 :

$$D_0 = \frac{-2}{n} \sum_{i=0}^n (y_i - (\beta_0 + \beta_1 x_i))$$

Pochodna po β_1 :

$$D_1 = \frac{-2}{n} \sum_{i=0}^n x_i (y_i - (\beta_0 + \beta_1 x_i))$$


Spadek gradientu



Używamy gradientu i współczynnika α

$$\beta_0 = \beta_0 - \alpha D_0$$

$$\beta_1 = \beta_1 - \alpha D_1$$



Więcej niż jedna wartość

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_p x_p$$

Wtedy:


$$\beta_0 = \beta_0 - \alpha D_0$$

$$\beta_1 = \beta_1 - \alpha D_1$$

...



$$\beta_p = \beta_p - \alpha D_p$$

Inne rodzaje regresji – regresja wielomianowa



$$y = \beta_0 + \beta_1 X + \beta_2 X^2 + \dots + \beta_p X^p$$

underfitting & overfitting



Regularyzacja – zapobiegamy overfittingowi

- Jeśli $\beta_0, \beta_1, \beta_2, \beta_3$ wynoszą kolejno 0.1, 0.2, 0.04, 500 to β_3 ma decydujący wpływ na wynik

$$\frac{1}{n} \sum_{i=0}^n (y_i - \text{pred})^2 + \lambda \sum_{j=0}^p \beta_j^2 \text{ – ridge regularization}$$

$$\frac{1}{n} \sum_{i=0}^n (y_i - \text{pred})^2 + \lambda \sum_{j=0}^p |\beta_j| \text{ – lasso regularization}$$

